

Casca Vault — 企業自建 AI 路由引擎

一行改動，降低 30-60% LLM 費用。部署在你的伺服器，資料不出你的網路。

什麼是 Casca Vault？

Casca Vault 是 Casca AI 路由引擎的**企業自建版本**。

你的團隊每天送出成千上萬筆 AI 請求給 GPT-4o。但其中 60% 的問題用便宜模型就能回答得一樣好。Casca Vault 自動判斷每筆請求的複雜度，把簡單問題送便宜模型、複雜問題送頂級模型，**在不犧牲品質的前提下，大幅降低你的 LLM 帳單**。

與 Casca 雲端版不同，**Vault 完整運行在你自己的伺服器上**。你的 prompt、資料、API Key 永遠不離開你的網路。

核心價值

 **省錢**

場景	不用 CASCA	用 CASCA VAULT	節省
客服聊天（月 100 萬筆）	\$5,000/月	\$1,500/月	70%
內容生成（月 50 萬筆）	\$2,500/月	\$1,000/月	60%
知識庫查詢（月 200 萬筆）	\$10,000/月	\$3,500/月	65%

原理：你的 60% 請求是「什麼是 X」「訂單狀態」這種簡單問題。GPT-4o 每百萬 token 收 \$5，但 Gemini Flash 只要 \$0.075，回答品質一樣好。Casca 自動把這些便宜的題目導到便宜的模型。

 資料安全


- **完全自建：**Docker Compose 部署在你的 VPC / 機房
- **零資料外傳：**Prompt 和回應永遠不離開你的伺服器
- **你的 LLM Key：**直接用你自己的 OpenAI / Anthropic / Google API Key
- **離線運行：**支援完全斷網環境（金融、政府、半導體）

 不影響速度

步驟	時間	說明
L1 規則分類	0.5 毫秒	160+ 條規則即時判斷
L2 MiniLM 補強	10 毫秒	只在低信心時啟動
LLM 回應	200-2000 毫秒	跟直連一樣
Casca 增加的延遲	< 15 毫秒	佔總延遲 < 1%

 準確率

三層分類架構，組合準確率 **95%+**：



品質分錯怎麼辦？最多是多花一點錢（把簡單問題送到貴的模型），絕不會因為省錢而犧牲回答品質。

怎麼整合？

改一程式碼：

```
# 改之前
client = OpenAI(api_key="sk-xxx")

# 改之後
client = OpenAI(
    api_key="sk-xxx",
    base_url="http://你的伺服器:3001/v1" # 指向 Casca Vault
)
```

就這樣。不用改 prompt、不用改邏輯、不用改任何業務程式碼。

部署架構

你的伺服器 (Docker Compose 一鍵啟動)

```
Casca Engine ↔ MiniLM Classifier
(API 閘道)      (補強判斷)
  ↓
PostgreSQL ↔ Casca Agent
(本地日誌)    (授權 + 用量回報)
你的 LLM Key → OpenAI / Anthropic / Google
```

最低需求：4 CPU • 8GB RAM • 50GB SSD • Docker

授權與計費

項目	說明
授權方式	年約 License Key
計費方式	按月 token 用量 (Agent 自動回報)
離線授權	支援 (RSA 簽章的 license.json, 完全斷網可用)
更新方式	自動推送 OTA 更新 (可設定手動審核)

管理工具

Casca 提供雲端管理後台 (Admin Dashboard)，讓你的團隊：

- 📊 **即時監控**：每個 Vault 部署的狀態、版本、用量
- 🔑 **授權管理**：新增、延長、撤銷 License
- 💰 **計費報表**：月度 token 用量彙總、費用明細
- 📦 **版本推送**：一鍵推送更新到指定客戶
- 📝 **稽核紀錄**：所有操作完整記錄

支援語言

Casca Vault 的分類引擎支援 **14 種語言**：

繁體中文 • 简体中文 • English • 日本語 • 한국어 • Français • Deutsch •
Español • Italiano • العربية • हिन्दी • ไทย • Tiếng Việt • Bahasa Indonesia

不只是翻譯：每種語言都有 native speaker 訓練的專屬規則，理解在地用語和文化語境。

跟其他方案的差別

功能	OPENAI 直連	LITELLM / OPENROUTER	
多模型支援	✗ 單家	✓ 多家 proxy	✓ 多家 proxy
智慧路由	✗ 手動選	✗ 手動規則	✓ 自動分類
自我改善	✗	✗	✓ Path B 持續學習
14 語言分類	✗	✗	✓
語意快取	✗	✗	✓ 預估 10-20% 命中率（依使用情境而異）
自建部署	N/A	✓	✓
程式碼保護	N/A	開源	✓ 編譯 Binary
授權管理	N/A	✗	✓
品質 SLA	✗	✗	✓ 合約保障

快速開始

1. 聯繫 Casca 取得 License Key
2. 拿到 Docker Compose 部署包
3. 5 分鐘部署 → 改一行程式碼 → 開始省錢

聯繫我們：casca@vastitw.com • <https://cascaio.com>

Casca Vault — AI 省錢，你全權掌控。